

Mini-AutoML dla Danych Tabelarycznych

Hanna Szczerbińska Helena Wałachowska
Paula Wołkowska

Politechnika Warszawska
Wydział Matematyki i Nauk Informacyjnych
Warsztaty badawcze

29.01.2026

Celem naszego projektu było:

- 1 stworzenie uproszczonego systemu AutoML, który umożliwiłby automatyczne wykonanie zadania klasyfikacji binarnej na dowolnym dostarczonym zbiorze danych,
- 2 skonstruowanie i wykorzystanie portfolio modeli.

Wybór modeli do portfolio

- Pierwsze 50 konfiguracji obejmowało sześć typów modeli.
- Wybór konkretnych wartości hiperparametrów odbywał się poprzez losowanie zestawów hiperparametrów na podstawie ręcznie wybranych zakresów.
- Do wstępnego portfolio z każdego typu modelu wylosowano ustaloną liczbę konfiguracji.

Przestrzeń przeszukiwań dla grupy 1

Typ modelu	Zakres wartości hiperparametrów	Liczba modeli
RandomForestClassifier	$n_estimators \in \{50, 100, 200, 500\}$ $max_depth \in \{10, 20, \text{None}\}$ (state: $min_samples_split=2$, $random_state=42$, $n_jobs=-1$)	10
XGBClassifier	$n_estimators \in \{100, 200, 300\}$ $max_depth \in \{5, 7, 10\}$ $learning_rate \in \{0.05, 0.1\}$ (state: $random_state=42$, $n_jobs=-1$, $eval_metric="logloss"$)	10
LGBMClassifier	$n_estimators \in \{100, 200\}$ $num_leaves \in \{31, 63, 127\}$ $learning_rate \in \{0.05, 0.1\}$ (state: $random_state=42$, $n_jobs=-1$, $verbose=-1$)	10
CatBoostClassifier	$iterations \in \{100, 200\}$ $depth \in \{6, 8\}$ $learning_rate \in \{0.05, 0.1\}$ (state: $random_state=42$, $verbose=False$, $allow_writing_files=False$)	8
SVC	$C \in \{1.0, 10.0\}$ $kernel \in \{\text{"rbf"}, \text{"poly"}\}$ $\gamma \in \{\text{"scale"}, \text{"auto"}\}$ (state: $random_state=42$, $probability=True$)	6
ExtraTreesClassifier	$n_estimators \in \{50, 100, 200\}$ $max_depth \in \{10, \text{None}\}$ (state: $random_state=42$, $n_jobs=-1$)	6
Suma		50

- Utworzono 28 modeli wraz z odpowiadającymi im konfiguracjami hiperparametrów.
- Procedura doboru wartości hiperparametrów była oparta na algorytmie Random Search o 15 iteracjach z trójkrotną walidacją krzyżową. Do oceny jakości predykcji użyto balanced accuracy.
- Wybór hiperparametrów modeli przeprowadzono na podstawie dziesięciu zbiorów danych pochodzących z OpenML o identyfikatorach: 31, 1464, 334, 50, 1504, 3, 1494, 1510, 1489 oraz 37.
- Procedura kalibracji modeli polegała na losowym wyborze czterech zbiorów danych dla każdego typu modelu oraz optymalizacji hiperparametrów dla każdego zbioru danych w oparciu o zdefiniowane zakresy wartości.

Przestrzeń przeszukiwań dla grupy 2

Typ modelu	Hiperparametr	Rozkład / zbiór wartości
SVM	C	uniform(0.01, 100)
	$kernel$	{rbf, linear, poly}
	γ	{scale, auto} \cup uniform(0.001, 1)
kNN	$n_neighbors$	randint(3, 20)
	$weights$	{uniform, distance}
	$metric$	{euclidean, manhattan, minkowski}
	p	randint(1, 3)
Naive Bayes	$var_smoothing$	uniform(10^{-12} , 10^{-6})
Gradient Boosting	$n_estimators$	randint(50, 300)
	max_depth	randint(3, 10)
	$learning_rate$	uniform(0.01, 0.3)
	$min_samples_split$	randint(2, 20)
	$min_samples_leaf$	randint(1, 10)
CatBoost	$n_estimators$	randint(50, 300)
	max_depth	randint(3, 10)
	$learning_rate$	uniform(0.01, 0.3)
	$min_data_in_leaf$	randint(1, 20)
LightGBM	$n_estimators$	randint(50, 300)
	max_depth	randint(3, 15)
	$learning_rate$	uniform(0.01, 0.3)
	$min_child_samples$	randint(5, 50)
	$subsample$	uniform(0.6, 1.0)
AdaBoost	$n_estimators$	randint(50, 300)
	$learning_rate$	uniform(0.1, 1.5)

- Dokonano ręcznego wyboru 22 modeli wraz z odpowiadającymi im konfiguracjami hiperparametrów, na podstawie wyników zewnętrznych eksperymentów opublikowanych na platformie OpenML.
- W szczególności uwzględniono wielowarstwowe sieci neuronowe MLP o architekturach charakteryzujących się malejącą liczbą neuronów w kolejnych warstwach, klasyczne klasyfikatory liniowe i nieliniowe (SVM, regresję logistyczną oraz klasyfikator kNN), a także metody zespołowe (Random Forest, AdaBoost oraz XGBoost) w kilku wariantach parametrów.

- Spośród wstępnie wybranych 100 modeli wyselekcjonowano 50 najlepszych konfiguracji.
- Selekcja została przeprowadzona na podstawie ewaluacji wszystkich 100 modeli na 15 zbiorach danych (5 małych, 5 średnich oraz 5 dużych), losowo wybranych z OpenML.
- Każdy model generował predykcje dla wszystkich 15 zbiorów danych, które były oceniane za pomocą balanced accuracy. Na tej podstawie dla każdego zbioru danych utworzono ranking modeli.
- Dla każdego modelu obliczono średnią pozycję w rankingach uzyskanych dla wszystkich zbiorów danych.
- Do ostatecznego portfolio zakwalifikowano konfiguracje o najwyższej średniej pozycji rankingowej.

Metoda selekcji modeli z portfolio dla nowego zbioru danych

- W zależności od liczby obserwacji w zbiorze treningowym wybierana jest liczba foldów walidacji krzyżowej: pięć dla mniejszych zbiorów danych (<10000) oraz trzy dla większych. (zachowujemy proporcję klas)
- Pierwszym etapem selekcji modeli jest szybki screening, w którym każdy model z portfolio trenowany jest na części danych treningowych (80%), a następnie oceniany na wydzielonym zbiorze walidacyjnym (20%) przy użyciu miary ROC-AUC obliczanej na podstawie ciągłych wyników predykcji (prawdopodobieństw lub wartości funkcji decyzyjnej).
- Spośród wszystkich modeli do kolejnego etapu przekazywana jest jedynie ustalona liczba najlepszych konfiguracji (domyślnie 15).

- W drugim etapie przeprowadzana jest pełna ewaluacja wyselekcjonowanych modeli z wykorzystaniem walidacji krzyżowej. Modele oceniane są do momentu wyczerpania budżetu czasowego.
- Jeżeli ensembling nie jest aktywny, wybierany jest pojedynczy model o najwyższej średniej wartości ROC-AUC. Model ten jest następnie trenowany ponownie na pełnym zbiorze treningowym.
- Na podstawie predykcji out-of-fold wyznaczany jest optymalny próg decyzyjny maksymalizujący wartość miary balanced accuracy, który zastępuje domyślny próg 0.5

Esembling

- Do ensemble mogą wejść maksymalnie pięć modeli, przy czym wprowadzono dodatkowe ograniczenie różnorodności polegające na tym, że z każdej rodziny algorytmów (np. modele drzewiaste, boostingowe, SVM) mogą zostać wybrane co najwyżej dwa modele.
- Po zakończeniu selekcji wszystkie modele wchodzące w skład ensemble są trenowane ponownie na pełnym zbiorze treningowym. Predykcje out-of-fold poszczególnych modeli są następnie uśredniane, a na ich podstawie wyznaczany jest wspólny próg decyzyjny maksymalizujący wartość miary balanced accuracy. W fazie predykcji ensemble stosuje miękkie głosowanie (soft voting), polegające na uśrednianiu prawdopodobieństw generowanych przez poszczególne modele, a następnie porównaniu uzyskanej wartości z nauczonym progiem decyzyjnym.

Wnioski

- Jakość predykcji możliwych do osiągnięcia przez stworzony system Mini-AutoML została oceniona na podstawie pięciu zbiorów testowych pochodzących z platformy OpenML oraz zbioru testowego X zaproponowanego w ramach zajęć.
- Eksperymenty przeprowadzono przy ograniczeniu czasowym wynoszącym 20 minut oraz przy pozostałych parametrach pozostawionych na wartościach domyślnych.
- Jakość predykcji uzyskanych na zbiorach danych pochodzących z platformy OpenML okazała się zadowalająca, osiągając wartości miary balanced accuracy bliskie 100% dla trzech z nich. Uzyskane wyniki są zgodne z rezultatami raportowanymi w literaturze oraz w niezależnych eksperymentach dostępnych dla tych zbiorów danych.

Wyniki eksperymentu

Zbiór danych	Tryb	Wybrany model / skład ensemble	Balanced Accuracy	Zakres prawdopodobieństw	Czas dopasowania [s]
Zbiór testowy X	Ensemble	ExtraTrees (2), RandomForest (2), SVC (1)	0.5586	[0.2952, 0.7586]	128.51
	Bez ensemble	ExtraTreesClassifier	0.5489	[0.2500, 0.8050]	137.03
credit-g (OpenML)	Ensemble	RandomForest (3), CatBoost (2)	0.7405	[0.2052, 0.9777]	330.54
	Bez ensemble	CatBoostClassifier	0.7333	[0.1355, 0.9780]	477.29
blood-transfusion-service-center (OpenML)	Ensemble	CatBoost (4), MLP (1)	0.6949	[0.0440, 0.7367]	32.96
	Bez ensemble	MLPClassifier	0.7027	[0.0107, 0.6830]	40.27
wdbc (OpenML)	Ensemble	SVC (1), ExtraTrees (1), CatBoost (1), XGBoost (2)	0.9453	[0.0004, 0.9996]	189.87
	Bez ensemble	SVC	0.9688	[0.0001, 1.0000]	106.56
monks-problems-2 (OpenML)	Ensemble	MLP (1), GradientBoosting (1), LightGBM (3)	0.9832	[0.0000, 0.9899]	108.09
	Bez ensemble	MLPClassifier	1.0000	[0.0000, 0.9977]	161.80
PhishingWebsites (OpenML)	Ensemble	GradientBoosting (1), LightGBM (4)	0.9722	[0.0000, 1.0000]	281.24
	Bez ensemble	LGBMClassifier	0.9733	[0.0000, 1.0000]	256.99